

Especificação Técnica de Arquitetura: Yawara System Neural Architecture – Valence Model Engine

Autor

Hélio Peres Martins Neto

Revisado Por

Data

01/02/2026

Resumo Executivo: Este documento formaliza a especificação técnica e arquitetural do Valence Engine, o módulo de inteligência artificial responsável pela otimização combinatória e alocação estratégica de recursos humanos dentro do ecossistema Yawara MotoStudent. A arquitetura aqui detalhada transcende a lógica de triagem individual do subsistema antecessor para abordar o problema complexo da formação de equipes multidisciplinares sob restrições rígidas de competência técnica e diversidade acadêmica. A solução implementa uma abordagem evolutiva baseada em Algoritmos Genéticos (GA) que opera sobre matrizes vetoriais de *Hard Skills*, buscando maximizar a cobertura técnica coletiva através do princípio de *Best-in-Slot* enquanto simultaneamente otimiza a sinergia pedagógica pela distribuição equilibrada de senioridade acadêmica. Adicionalmente, o sistema incorpora uma Base de Conhecimento Dinâmica capaz de ingerir, normalizar e valorar competências não previstas no dicionário original, assegurando que a taxonomia de avaliação evolua organicamente em consonância com a realidade curricular dos candidatos.

PALAVRAS-CHAVE: Otimização Combinatória; Algoritmos Genéticos; Alocação de Recursos Humanos; Matrizes Vetoriais; PyGAD; Best-in-Slot; Explainable AI (XAI).

Technical Architecture Specification: Yawara System

Neural Architecture – Valence Model Engine

Abstract: This document formalizes the technical and architectural specification of the Valence Engine, the artificial intelligence module responsible for combinatorial optimization and strategic human resource allocation within the Yawara MotoStudent ecosystem. The architecture detailed herein transcends the individual screening logic of the predecessor subsystem to address the complex problem of forming multidisciplinary teams under strict constraints of technical competence and academic diversity. The solution implements an evolutionary approach based on Genetic Algorithms (GA) operating on *Hard Skills* vector matrices, seeking to maximize collective technical coverage through the *Best-in-Slot* principle while simultaneously optimizing pedagogical synergy via the balanced distribution of academic seniority. Additionally, the system incorporates a Dynamic Knowledge Base capable of ingesting, normalizing, and valuing competencies not foreseen in the original dictionary, ensuring that the evaluation taxonomy evolves organically in line with the candidates' curricular reality.

KEYWORD: Combinatorial Optimization; Genetic Algorithms; Human Resource Allocation; Vector Matrices; PyGAD; Best-in-Slot; Explainable AI (XAI).

1. INTRODUÇÃO

A gênese do subsistema **Valence** emerge da necessidade crítica de transcender a tradicional triagem linear de candidatos para adentrar o domínio da engenharia de times de alta performance. O nome "Valence" (Valência) não é uma escolha estética, mas uma definição funcional rigorosa derivada da química: assim como a valência de um átomo determina sua capacidade de se ligar a outros para formar moléculas estáveis, o Valence Engine analisa as propriedades individuais de cada estudante — suas competências técnicas, soft skills e maturidade acadêmica — para calcular as "ligações covalentes" ótimas que resultam em equipes multidisciplinares resilientes. No contexto do projeto Yawara MotoStudent, um candidato isolado, por mais brilhante que seja, comporta-se como um átomo instável; é somente através da combinação precisa com perfis complementares que se atinge a estabilidade operacional necessária para desenvolver um protótipo veicular competitivo.

O problema central que motivou o desenvolvimento desta arquitetura reside na falha sistêmica dos métodos tradicionais de formação de grupos em ambientes acadêmicos e corporativos. Historicamente, a alocação de recursos humanos tende a seguir dois padrões ineficientes: a aleatoriedade administrativa, que frequentemente gera "silos de competência" (equipes com redundância de habilidades em uma área e vacância completa em outra), ou o viés de afinidade, onde a formação de "panelinhas" baseadas em amizade prévia anula a diversidade cognitiva e a troca de experiências intergeracional. O Valence Model Engine foi concebido como a antítese algorítmica desses cenários. Ao operar após a etapa de filtragem individual (o "Portão de Ferro"), este motor assume que todos os inputs são válidos, deslocando o desafio matemático da *seleção* para a *otimização combinatória*. A solução proposta utiliza Algoritmos Genéticos para simular milhares de permutações de equipes por segundo, buscando configurações que maximizem a cobertura vetorial de conhecimento (Hard Skills) enquanto forçam matematicamente a heterogeneidade de semestres letivos.

No âmbito da academia e da extensão universitária, a introdução do Valence representa uma mudança de paradigma na gestão educacional. A universidade moderna prega a interdisciplinaridade, mas carece de ferramentas instrumentais para garanti-la na prática. O Valence Engine instrumentaliza esse conceito ao garantir que um estudante de Engenharia Mecânica com profundidade em Termodinâmica seja sistematicamente pareado com um estudante de Engenharia de Software versado em Sistemas Embarcados

e um gestor com noções de liderança. Para o Projeto Yawara, isso significa que a transferência de conhecimento deixa de ser um acidente feliz para se tornar uma política algorítmica: ao ponderar a diversidade de semestres como um fator crítico de aptidão (fitness) do time, o sistema assegura a perenidade do projeto, criando microambientes de mentoria onde veteranos são compelidos a tutelar calouros, garantindo a sucessão técnica e a preservação do *know-how* institucional.

Tecnologicamente, o Valence se distingue das soluções de mercado atuais, como os sistemas de rastreamento de candidatos (ATS) convencionais utilizados por grandes corporações. Enquanto ferramentas como Gupy ou Workday focam primariamente no ranqueamento linear de indivíduos contra uma descrição de vaga estática, o Valence introduz o conceito de "Base de Conhecimento Dinâmica" e avaliação *Best-in-Slot*. Diferente de sistemas rígidos que exigem taxonomias predefinidas, o Valence é capaz de ler o universo amostral dos currículos apresentados, aprender novas competências emergentes e valorar o "poder de fogo" de um time baseando-se não na média de seus membros, mas na soma de seus picos de excelência. Essa abordagem, fundamentada em princípios de *Explainable AI* (XAI), não apenas entrega a lista de times, mas gera dossiês analíticos que justificam a formação de cada esquadrão, oferecendo um nível de transparência e sofisticação decisória raramente encontrado mesmo em softwares de gestão de capital humano de nível empresarial.

2. STACK TECNOLÓGICO

A implementação do Valence Engine foi arquitetada sobre o ecossistema Python 3.11+, escolha justificada não apenas pela ubiquidade da linguagem no meio acadêmico e científico, mas pela sua capacidade incomparável de orquestração entre operações de I/O (Input/Output) e computação matricial densa. No núcleo do processamento matemático, a arquitetura abandona as estruturas de dados nativas do Python (listas e dicionários) em favor de arranjos vetoriais geridos pela biblioteca NumPy. Essa decisão é crítica para a performance do sistema: ao representar as notas e competências dos candidatos como matrizes numéricas contíguas em memória, o sistema reduz o *overhead* de processamento e permite que as operações de álgebra linear necessárias para o cálculo do *Fitness Score* (como somas ponderadas e desvios padrão) sejam executadas em baixo

nível (C/C++), garantindo latência mínima mesmo ao processar centenas de milhares de permutações de times por geração evolutiva.

Embora o Valence Engine opere primariamente sobre a lógica de Algoritmos Genéticos (implementada via PyGAD), ele é um componente indissociável do ecossistema Y-SNA, que utiliza TensorFlow e Keras nas camadas antecedentes de ingestão e normalização. A interdependência arquitetural se manifesta no tratamento dos dados brutos: antes que o Valence possa alocar um candidato, o histórico escolar (frequentemente um PDF não estruturado) passa por redes neurais de Processamento de Linguagem Natural (NLP) para a canonização de disciplinas. O TensorFlow atua aqui como o "tradutor" universal, convertendo variações linguísticas (ex: "Calc. Numérico" vs "Métodos Numéricos") em tokens padronizados que o Valence pode consumir matematicamente. Portanto, a arquitetura é híbrida: utiliza Deep Learning para estruturação de dados (fase de percepção) e Computação Evolutiva para otimização combinatória (fase de decisão).

No que tange à infraestrutura e hospedagem, o sistema adota uma abordagem de microsserviços containerizados via Docker. Essa estratégia isola o ambiente de execução, eliminando o clássico problema de "funciona na minha máquina" e garantindo que as bibliotecas de sistema necessárias para a renderização de relatórios (como Pango e Cairo utilizadas pelo WeasyPrint) estejam sempre presentes e na versão correta, independentemente do sistema operacional do servidor hospedeiro (seja um servidor local da universidade ou uma instância cloud AWS/GCP). A arquitetura de contêineres também facilita a escalabilidade horizontal, permitindo que múltiplas instâncias do orquestrador sejam levantadas para atender a picos de demanda durante a semana de encerramento das inscrições do processo seletivo.

Um dos maiores desafios técnicos enfrentados e solucionados nesta arquitetura refere-se ao gerenciamento de recursos de hardware, especificamente memória RAM e limites de transferência de rede (Network Throughput). O download e processamento simultâneo de centenas de arquivos PDF de históricos escolares representam um risco significativo de *Buffer Overflow* ou exaustão de memória. Para mitigar isso, o ValenceOrchestrator implementa um padrão de *Bounded Semaphore* (Semáforo Limitado) sobre uma arquitetura assíncrona (asyncio). Diferente de uma abordagem linear (que seria lenta demais) ou puramente paralela (que colapsaria a memória ou sofreria *rate limiting* por parte do banco de dados/storage), o sistema controla estritamente a concorrência. Se definirmos um semáforo de 5 *slots*, o sistema baixará e processará no

máximo 5 arquivos simultaneamente; assim que um libera a memória (após a extração dos dados), outro entra na fila. Isso mantém a curva de consumo de RAM estável e previsível, prevenindo o congelamento do servidor mesmo em hardware modesto com limitações de CPU.

Por fim, a distinção entre o uso de CPU e GPU é vital nesta arquitetura. Enquanto os módulos de treinamento de redes neurais do Y-SNA se beneficiam massivamente da aceleração por GPU (CUDA cores), o Valence Engine, por sua natureza de algoritmo genético com dados tabulares, é uma aplicação predominantemente *CPU-Bound*. A performance da forja de times depende diretamente do *clock* do processador e do número de núcleos disponíveis para paralelizar as avaliações de fitness da população. Portanto, a especificação de hardware para o nó de processamento do Valence prioriza processadores *multi-core* de alta frequência e uma quantidade generosa de memória RAM rápida para sustentar as matrizes populacionais, dispensando a necessidade de placas gráficas dedicadas para esta etapa específica do pipeline, o que otimiza os custos operacionais do projeto.

3. DEFINIÇÃO DE DADOS E INGESTÃO

A integridade do Valence Engine depende estritamente da normalização dos dados de entrada. Diferente de sistemas legados que operam sobre bancos de dados relacionais simples, o Valence adota uma arquitetura orientada a objetos serializáveis, onde cada entidade representa um vetor matemático pronto para processamento. Abaixo, detalham-se as estruturas de dados fundamentais (Schemas) que governam o fluxo de informação do sistema.

3.2. 3.2. Estruturas de Entrada (Input Domain)

A unidade atômica de processamento do Valence é o **Perfil do Candidato** (CandidateProfile). Este objeto não é apenas um registro cadastral, mas uma representação vetorial das capacidades do indivíduo. A construção deste objeto é responsabilidade do *Valence Orchestrator*, que o compila a partir dos dados brutos extraídos dos PDFs de histórico escolar e das notas do Portão de Ferro.

```
class CandidateProfile(BaseModel):
    id: str
    name: str
    semester: int
    academic_record: List[SubjectRecord]
    iron_gate_score: List[float] = Field(default_factory=lambda: [0.0]*5)
```

3.3. Estruturas de Saída (Output Domain)

O artefato final gerado pelo processo de otimização é o objeto **Resultado da Forja** (ForgeOutput). Este objeto encapsula a solução ótima encontrada pelo Algoritmo Genético e serve como fonte de verdade para a geração dos relatórios PDF e para a persistência no banco de dados.

```
class ForgeOutput(BaseModel):
    algorithm: str = "Valence Engine v5.0"
    total_fitness: float
    processing_time: float
    squads: List[ForgedSquad]
```

4. ARQUITETURA E MODELAGEM MATEMÁTICA

A arquitetura lógica do Valence Engine opera sob o paradigma de *Pipeline de Processamento Vetorial*, onde o fluxo de dados é segregado em três estágios distintos e sequenciais: Ingestão e Normalização (responsabilidade do ValenceOrchestrator), Otimização Combinatória (executada pelo núcleo ValenceEngine) e Renderização de Resultados (camada de XAI). O Orquestrador atua como o controlador mestre do sistema, gerenciando a concorrência de I/O através de semáforos assíncronos para buscar os dados brutos dos candidatos e submetê-los à normalização canônica. Nesta fase, o histórico escolar de cada indivíduo deixa de ser um documento textual e é transmutado em um vetor esparsa de competências, onde cada dimensão corresponde a uma disciplina acadêmica (ex: Cálculo I, Termodinâmica, Algoritmos). Para garantir a adaptabilidade do sistema a diferentes grades curriculares, o Orquestrador implementa um mecanismo de construção de **Base de Conhecimento Dinâmica**: em vez de forçar os dados a caberem em uma tabela predefinida, o sistema varre a união de todas as disciplinas cursadas pela

população de candidatos atual e constrói a matriz de pesos em tempo de execução. Disciplinas catalogadas na base de referência recebem pesos calibrados (Variável W_{ref}), enquanto disciplinas novas ou desconhecidas são automaticamente ingeridas com peso neutro, assegurando que nenhum esforço acadêmico seja descartado do cálculo vetorial.

O núcleo matemático da solução reside na modelagem do problema de alocação como um desafio de **Otimização Combinatória**, resolvido através de Algoritmos Genéticos (GA). Diferente de métodos lineares que buscariam uma solução "correta" única, o GA explora um vasto espaço de soluções possíveis através de processos estocásticos inspirados na evolução biológica. Um "indivíduo" (cromossomo) na população do algoritmo não é um candidato, mas sim uma permutação completa de todos os índices dos candidatos disponíveis. O sistema inicializa uma população de soluções aleatórias e, ao longo de sucessivas gerações, aplica operadores de *Crossover* (cruzamento de arranjos de times) e *Mutação* (troca de membros entre times) para convergir em direção a uma configuração ótima. A qualidade de cada solução é avaliada por uma **Função de Fitness Global (F)**, que busca maximizar o "Poder de Combate" dos times enquanto minimiza o desequilíbrio entre eles.

Matematicamente, a avaliação de um time T não segue a lógica da média aritmética simples, que penalizaria grupos heterogêneos, mas sim o princípio de **Cobertura Máxima (Best-in-Slot)**. Para cada competência k no universo de disciplinas, a nota do time $S_{T,k}$ é definida pelo valor máximo encontrado entre seus membros: $S_{T,k} = \max(g_{1,k}, g_{2,k}, \dots, g_{n,k})$, onde $g_{i,k}$ é a nota do membro i na disciplina k . Isso modela a realidade operacional de engenharia, onde a presença de um único especialista em uma área crítica (como Eletrônica de Potência) é suficiente para cobrir a demanda do grupo, independentemente da ignorância dos demais membros sobre aquele tópico específico. O **Power Score (P_T)** do time é, portanto, o produto escalar entre o vetor de melhores notas do time e o vetor de pesos das disciplinas: $P_T = \sum(S_{T,k} \cdot W_k)$.

Simultaneamente à maximização técnica, o modelo impõe restrições de diversidade pedagógica através do cálculo de **Sinergia (D_T)**, definido pelo desvio padrão dos semestres letivos dos membros do time. A função de fitness global recompensa times com alta variância de semestres (mistura de calouros e veteranos) e penaliza configurações homogêneas ("panelinhas"). Adicionalmente, para garantir a justiça do

processo seletivo, o algoritmo aplica penalidades exponenciais baseadas no desvio padrão dos scores médios entre os diferentes times formados. Isso força o sistema a "distribuir a riqueza", impedindo a concentração de todos os candidatos de alta performance em um único "Super Time" e garantindo que todas as equipes tenham viabilidade técnica comparável. Por fim, a arquitetura trata matematicamente os casos de borda (divisão não inteira de candidatos) através de uma lógica de **Alocação Adaptativa**: quando o número de candidatos não é múltiplo do tamanho do time, o sistema ajusta dinamicamente a topologia dos vetores para criar esquadrões de apoio com tamanho reduzido, normalizando seus scores para evitar que a menor quantidade de membros distorça a avaliação de sua densidade de talento.

5. PROTOCOLOS DE TRANSPARÊNCIA E INTERPRETAÇÃO DO RELATÓRIO XAI

A filosofia de design do Yawara-SNA rejeita a noção de "Caixa Preta", onde decisões algorítmicas são aceitas sem questionamento. Em seu lugar, o Valence Engine implementa uma interface de *Explainable AI* (XAI) que materializa a lógica de alocação em um documento auditável: o Relatório de Forja. Este artefato não serve apenas como uma lista de chamada, mas como um painel de instrumentação para a gestão do projeto, oferecendo diagnósticos precisos sobre a saúde técnica e social de cada esquadrão formado. A leitura correta deste relatório é fundamental para que os líderes de núcleo possam atuar cirurgicamente no desenvolvimento de seus membros.

5.2. POWER SCORE

A estrutura do relatório é organizada em "Cartões de Esquadrão", onde o cabeçalho escuro apresenta as métricas vitais de desempenho coletivo. O primeiro e mais crítico indicador é o **POWER (Power Score)**, ou Índice de Potência Técnica. Diferente de uma média escolar, este valor representa a "soma vetorial das melhores competências" do time. Um POWER elevado (acima de 60.0) indica que o grupo possui especialistas de ponta cobrindo a maioria das áreas críticas do projeto, operando sob a lógica de *Best-in-Slot*: a deficiência de um membro em Termodinâmica é irrelevante para o score se houver

outro membro especialista no tema que possa assumir a responsabilidade técnica. Portanto, o POWER mede a autossuficiência do esquadrão para resolver problemas complexos sem ajuda externa.

5.3. DIVERSITY SCORE (DIV)

Ao lado da potência técnica, o relatório exhibe o **DIV (Diversity Score)**, que quantifica a Sinergia Intergeracional. Matematicamente derivado do desvio padrão dos semestres letivos dos membros, este índice revela o potencial de troca de conhecimento. Um valor de DIV próximo de zero alerta para a formação de "bolhas" (times compostos exclusivamente por calouros ou formandos), enquanto valores superiores a 2.0 indicam um ecossistema saudável de mentoria, onde a experiência dos veteranos pode fluir organicamente para os novatos.

5.4. IRON GASE MEAN (IG)

O terceiro indicador, **IG (Iron Gate Mean)**, atua como um nivelador de "Capacidade de Execução", refletindo a média de desempenho dos integrantes na fase de triagem inicial. Este número serve como um controle de qualidade global, assegurando que nenhum time seja sobrecarregado com membros que apresentaram dificuldades básicas nos testes de entrada.

5.5. PONTOS DE ATENÇÃO

No nível individual, a tabela de alocação introduz o conceito de **ROLE SUGERIDA** (Função Tática). O algoritmo não apenas agrupa pessoas, mas sugere seus papéis com base na maturidade acadêmica (semester). Membros identificados com *Role* de "Liderança Técnica" (geralmente finais de curso) são implicitamente designados como pontos focais para tomada de decisão, enquanto perfis "Operacionais" ou de "Aprendizado" (início de curso) devem ser guiados em tarefas de execução

supervisionada. Essa taxonomia automática elimina a ambiguidade inicial da formação do grupo, estabelecendo uma hierarquia funcional clara desde o primeiro dia.

Por fim, a seção analítica no rodapé de cada cartão traduz os vetores numéricos em linguagem natural através dos campos **FORTALEZAS** e **PONTOS DE ATENÇÃO**. O sistema varre a matriz de competências do time e destaca as disciplinas onde o grupo excede a excelência (ex: "Programação Aplicada", "Cálculo III"), validando a capacidade do time de enfrentar desafios nessas áreas. Simultaneamente, o motor de inferência identifica "Gaps Críticos" — disciplinas de alto peso (como Eletrônica de Potência ou Resistência dos Materiais) onde nenhum integrante atingiu o limiar mínimo de proficiência. Este diagnóstico de ausência é o recurso mais valioso para a gestão, pois aciona imediatamente a necessidade de intervenção externa, seja através de workshops de nivelamento ou do acompanhamento próximo por um professor tutor, mitigando riscos técnicos antes mesmo que o projeto inicie.

6. GOVERNANÇA, AUDITORIA E TRANSPARÊNCIA

A implementação de sistemas de decisão automatizada em ambientes acadêmicos e extensionistas impõe um rigor ético superior ao de aplicações comerciais convencionais. O Valence Engine foi arquitetado sob a premissa de que a integridade do Processo Seletivo Yawara é um ativo inegociável. Para assegurar a confiança institucional, a solução adota um modelo de **Governança por Design**, onde mecanismos de rastreabilidade, auditoria e proteção de dados não são funcionalidades periféricas, mas componentes intrínsecos do fluxo de processamento. A integridade do processo de alocação é garantida matematicamente através de funções de hash criptográfico. Cada Relatório de Forja gerado recebe um identificador único (Hash MD5) calculado a partir da semente aleatória utilizada e do estado final da função de fitness. Esse mecanismo cria um selo de imutabilidade: qualquer alteração posterior na composição dos times ou nas notas dos candidatos resultaria em um hash divergente, permitindo que a coordenação do projeto ou órgãos de controle externos validem a autenticidade dos documentos a qualquer tempo, assegurando que os critérios de formação não foram manipulados manualmente após a execução do algoritmo.

No que tange à transparência algorítmica e equidade (Fairness), o sistema enfrenta proativamente o risco de viés sistêmico. A arquitetura de **Base de Conhecimento**

Dinâmica atua como um nivelador de oportunidades, mitigando discriminações decorrentes de diferenças curriculares entre instituições ou cursos. Ao atribuir automaticamente um peso neutro a disciplinas desconhecidas em vez de descartá-las, o Valence assegura que candidatos oriundos de grades curriculares atípicas não sejam penalizados por terminologias distintas, garantindo que o "esforço acadêmico" seja a única variável de diferenciação. Além disso, a separação estrita entre o identificador do candidato (UUID) e seus atributos pessoais durante o processamento do Algoritmo Genético assegura uma "cegueira ética": o núcleo matemático otimiza vetores numéricos de competência, ignorando variáveis sensíveis como gênero, etnia ou idade, o que blinda o processo contra preconceitos inconscientes que frequentemente permeiam a seleção humana manual.

A conformidade com a **Lei Geral de Proteção de Dados (LGPD - Lei nº 13.709/2018)** é endereçada através de uma estratégia de Minimização de Dados e Ciclo de Vida Efêmero. O Valence Orchestrator opera segundo o princípio do *Need-to-Know*: o download dos históricos escolares e a extração de notas ocorrem em memória volátil (RAM) dentro de contêineres isolados, e os arquivos brutos são descartados imediatamente após a vetorização. O banco de dados persistente armazena apenas os metadados necessários para a gestão do ciclo de vida do projeto (Scores, IDs e Alocação), evitando a retenção desnecessária de documentos pessoais sensíveis. Para fins de treinamento futuro das redes neurais (Melhoria Contínua), o sistema implementa um protocolo de Anonimização Irreversível ao final de cada ciclo seletivo, onde os vínculos entre os vetores de desempenho acadêmico e a identidade civil dos estudantes são rompidos, transformando dados pessoais em dados estatísticos agregados, permitindo a evolução da inteligência artificial sem comprometer a privacidade individual dos participantes pretéritos.